

LibOrtho 理论框架深度批判性评审报告：几何隔离假说、曲率二元性与数学严密性的解构

收件人：博士研究生 [姓名]

发件人：Prof. [已隐去]

所属：麻省理工学院 (MIT) 电子工程与计算机科学系 / 脑与认知科学系

日期：2025年12月4日

主题：关于 "LibOrtho: 通过几何隔离解耦通用智能与记忆化" 的理论审计与批判性导读
请坐。

你发给我的这篇关于 "LibOrtho" 的论文¹我已经通读了三遍。你说你被其中"几何暴论"所吸引，认为它可能是解决大语言模型 (LLM) 隐私问题的银弹。作为你的导师，我必须首先浇一盆冷水，然后再给你递一块热毛巾。

这篇论文确实非常挑衅。在当前的学术界，大多数人还在通过微调 (Fine-tuning) 或差分隐私 (Differential Privacy, DP) 的统计噪声来修补隐私漏洞时，这群作者跳出来说："错了，隐私不是数据的问题，是几何的问题。"¹。他们试图通过物理架构 (Architecture) 而非算法后处理 (Algorithm) 来解决问题，这在哲学上是极其吸引人的——就像在软件层面修补不了的漏洞，他们试图直接拔掉硬件。

然而，作为MIT的博士生，你不能被这种宏大的叙事冲昏头脑。我们需要像外科医生一样解剖这篇论文。我们需要剥开它华丽的工程外衣 (那些CUDA内核优化、双流GEMM虽然精彩，但只是术)，直抵它的理论核心 (这是道)。

这份报告将长达两万字，因为我们要极其详尽地审查其三个核心理论支柱：

- 几何隔离假说 (**Geometric Isolation Hypothesis**)：隐私真的只是高维流形上的一个法向尖刺吗？
- 曲率二元性 (**Duality of Curvature**)：他们如何调和 Merullo 的“通用知识是高曲率”与他们自己的“隐私是高曲率”这一看似矛盾的结论？
- 数学推导的严密性 (**Mathematical Rigor**)：那个基于影响函数 (Influence Functions) 的定理 2，以及那个致命的“对角化近似”，到底站不站得住脚？

这将是一次漫长的理论探险。准备好你的笔记本。

1. 引言：从统计学迷雾到几何学硬核

在深入公式之前，我们需要先建立直觉。目前的隐私保护范式，无论是差分隐私 (DP-SGD) 还是

机器遗忘 (Machine Unlearning), 本质上都是在玩弄概率。

差分隐私试图在汤里加水(噪声), 稀释盐(隐私)的味道, 但这往往会让整锅汤变得寡淡无味(模型性能下降)。机器遗忘则试图通过逆向梯度更新把盐捞出来, 但这通常需要极其昂贵的计算, 而且你永远不知道是不是捞干净了¹。

LibOrtho 提出了一种完全不同的世界观。他们认为:

- 通用知识 (**General Knowledge**): 如语法、逻辑、常识, 是模型权重的“低频分量”, 它们构成了参数空间中的一个低维流形 \mathcal{M}_{pub} 。
- 特异性知识 (**Specificity**): 包括隐私 (如张三的身份证号) 和天才能力 (如高精度数学推理), 是这个流形上的“高频扰动” Δw 。

这是一个极其物理主义的视角。如果这个假设成立, 那么隐私保护就不再是一个优化问题, 而变成了一个信号处理问题——我们只需要设计一个低通滤波器 (Low-pass Filter), 滤掉高频分量, 隐私自然就消失了。

量化 (Quantization), 在他们眼中, 不再是压缩技术, 而正是这个滤波器。

“我们提出一个几何暴论: 隐私不是数据的属性, 而是模型参数的几何属性... 量化无意中压缩了模型的高维流形, 将‘通用智能’与‘私有记忆’纠缠在了一起。”¹

这句话是整篇论文的文眼。接下来的章节, 我们将验证这个“暴论”的数学基础。

2. 几何隔离假说: 高维流形上的幽灵

2.1 流形假设与量化的几何解释

作者首先重新定义了量化。通常我们认为量化是为了省显存, $w \approx q$ 。但作者将其形式化为一种几何投影。

设 w^* 为原始的全精度权重, $\mathcal{Lattice}$ 为量化格点 (例如 INT4 的离散值集合)。量化过程被描述为寻找流形上最近的格点:

$$w_{\text{base}} = \arg \min_{q \in \text{Lattice}} \|w^* - q\|_H$$

这里, $\|\cdot\|_H$ 表示基于 Hessian 加权的范数 1。这一步非常关键, 他们没有使用欧几里得距离, 而是使用了与损失函数曲率相关的距离, 这意味着他们在投影时考虑了对模型输出的影响。然后, 他们定义了残差 (Residual):

$$\Delta w_{\text{perp}} = w^* - w_{\text{base}}$$

LibOrtho的核心赌注在于：这个残差 Δw_{\perp} 并非随机噪声，而是编码了所有“特异性”信息的载体。

批判性分析：正交性的幻觉

作者使用符号 \perp 暗示这个残差分量与基础流形是正交的(Orthogonal)。在低维欧氏空间中，投影残差确实垂直于投影面。但在非凸的神经网络损失景观中，这种“正交性”是极其复杂的。

论文中定义的“纠缠度”(Entanglement Degree)指标泄露了天机：

$$\text{Entanglement}(z_i) = \frac{\|P_{\{\mathcal{S}\}_{\text{gen}}}\nabla l(z_i)\| \cdot \|P_{\{\mathcal{S}\}_{\text{mem}}}\nabla l(z_i)\|}{\|\nabla l(z_i)\|^2}$$

实验数据显示，对于大多数样本，纠缠度在 0.1 到 0.3 之间¹。这意味着 \mathcal{S}_{mem} (记忆子空间) 和 \mathcal{S}_{gen} (通用子空间) 并非完美的直角关系。

导师洞察：

你要明白，在高维空间中，“几乎正交”是常态(Blessing of Dimensionality)，但对于安全领域，“几乎”是不够的。如果一个隐私数据点(比如Canary字符串)的梯度主要落在 Δw_{\perp} 方向，但在 w_{base} 方向上也有非零投影，那么当你切断 Δw_{\perp} 时，你并没有完全消除这个记忆，你只是移除了它的“主成分”。

这就解释了为什么在 Canary 提取实验中，即使 $\alpha=0$ ，提取率也不是绝对的 0%，而是 0.3% (虽然接近随机，但仍有残留)¹。这也解释了为什么他们需要引入“对偶差分隐私”(Dual Differential Privacy) 来处理可能的残留。

2.2 脆性知识与鲁棒知识的几何分离

这是论文中最精彩，也最令人深思的概念创新。

作者发现，当把正交流的系数 α 设为 0 时(即只保留 INT4 的 Base 流)：

1. 隐私泄露(Canary Extraction)消失了(98.5% -> 0.3%)。
2. 通用能力(MMLU)几乎不变(68.1% -> 66.5%)。
3. 数学推理(GSM8K)大幅下降(68% -> 45%)。

这揭示了一个深刻的几何事实：精确推理(数学)和机械记忆(隐私)在几何结构上是同构的。

“我们证明了脆性知识(包括隐私和精确计算)与鲁棒知识(模糊推理和语法)的几何分离。”¹

分辨率缩放智能 (Resolution-Scaled Intelligence)

作者提出了“分辨率缩放智能”的概念。这非常有意思。想象一张高分辨率的照片，如果你把它模糊处理(量化)：

- 你依然能看清这是一只猫(通用知识, MMLU)。
- 但你看不清猫项圈上的微小文字(隐私)。

- 你也看不清猫胡须的精确数量(数学推理)。

导师批判:

这意味着 LibOrtho 实际上创造了一个“智商分级”系统。

- Base Mode ($\alpha=0$):** 这是一个“平庸但安全”的模型。它会聊天, 懂语法, 但算不对数, 也记不住你的生日。
- Pro Mode ($\alpha=1$):** 这是一个“天才但危险”的模型。它能解微积分, 但也可能泄露训练数据中的机密。

作为一个博士生, 你必须追问: 我们能否构建一个“天才且安全”的模型?

根据 LibOrtho 的几何假设, 答案可能是悲观的“不能”。因为“天才”要求权重的精确微调(High Precision), 而这种微调在几何上表现为高频尖刺(Outlier), 这与隐私的几何特征无法区分。这就像是你能不能要求一个相机只拍清楚胡须的数量, 却拍不清楚项圈上的字, 因为它们都是高频信息。

LibOrtho 的解决方案不是去区分它们(算法上很难), 而是把它们打包在一起, 给用户一个开关。这是工程上的妥协, 也是理论上的诚实。

2.3 威胁模型与攻击面的几何解释

为了验证这个几何假设, 作者引入了多种攻击场景。我们需要特别关注 白盒梯度攻击(White-box Gradient Attack)¹。

如果隐私信息真的被隔离在正交流 W_{ortho} 中, 那么当我们计算损失函数关于隐私样本 z_{priv} 的梯度时, 这个梯度的能量应该主要集中在 W_{ortho} 对应的权重上。

实验结果验证了这一点:

- 当 $\alpha=1$ 时, 梯度存在且指向特定的记忆方向。
- 当 $\alpha=0$ 时, $\nabla_{W_{base}} l(z_{priv})$ 的模长相比完整模型减少了 99.2%¹。

这意味着, 对于基础流 W_{base} 而言, 隐私样本看起来就像是噪声, 或者说, W_{base} 所在的流形对于隐私样本的梯度方向是“平坦”的(导数为0)。这强有力地支持了“几何隔离”的物理真实性。

3. 曲率二元性: 调和矛盾的理论基石

这是你这篇评审报告中最需要浓墨重彩的一笔。这篇论文解决了一个困扰学术界已久的矛盾。

3.1 矛盾的起源

在此之前, 关于曲率(Hessian 特征值)与模型能力的关系, 存在两种截然相反的观点:

- Merullo 等人 (2024)** 基于 Fisher Information Matrix (K-FAC) 的研究指出: 通用推理能力依赖于高曲率方向。逻辑是: 通用知识(如 $1+1=2$)被海量数据共享, 因此这些方向极其“刚性”, 任何微小的扰动都会导致全局损失剧烈上升。

2. **LibOrtho** 的直觉: 隐私记忆依赖于高曲率方向。逻辑是: 为了记住一个罕见的离群点 (Outlier), 模型必须在权重空间形成一个尖锐的极小值 (Spike)。

如果两者都依赖高曲率, 那我们如何通过曲率来分离它们?

3.2 实例级 vs. 种群级: 爱因斯坦式的统一

LibOrtho 的作者极其敏锐地指出了上述矛盾的根源在于参考系的混淆。他们引入了“二元性”(Duality) 定义:

维度	实例级曲率 (Instance-Level)	种群级曲率 (Population-Level)
数学定义	$\nabla^2 l(z_i, \theta)$ (单个样本 Hessian)	$\mathbb{E}[\nabla^2 l(z, \theta)]$ (Fisher Information / Average Hessian)
物理意义	单个数据点对权重的敏感度	整个数据分布对权重的平均敏感度
通用知识表现	低曲率 (相对单个样本是平庸的)	高曲率 (被所有样本加强, 形成刚性结构)
隐私记忆表现	极高曲率 (为了拟合离群点形成的尖刺)	低曲率 (在平均化中被稀释, 显得平坦)
LibOrtho 关注点	关注 (识别权重异常值)	忽略

导师解读:

这个表格 1 是理解整篇论文的钥匙。

- Merullo 研究的是种群级。在宏观统计上, 通用规则是“硬”的, 因为所有人都在用; 隐私是“软”的, 因为只有一个人在用, 平均下来就没了。
- LibOrtho 研究的是实例级。在微观个例上, 隐私数据是“硬”的, 因为它是一个离群点 (Outlier), 模型必须为了它专门扭曲权重空间; 而通用规则对单个样本来说反而没那么敏感 (因为已经在预训练中學會了)。

LibOrtho 的筛选机制 $\text{Impact}_{ij} = (w_{ij} - q_{ij})^2 \cdot H_{jj}$ 实际上是在寻找个别权重的异常高值。它不在乎这个方向在平均意义上是否重要, 它只在乎这个权重为了拟合当前样本是否偏离了量化格点太远。

3.3 定理1: Outlier 样本与 Hessian 尾部

为了从数学上形式化这一点，作者提出了定理1¹。

定义 Inlier vs Outlier:

- **Inlier**(内点): 梯度方向与平均梯度方向一致 ($\cos \approx 1$)。
- **Outlier**(离群点): 梯度方向与平均梯度几乎正交。隐私数据通常是 Outlier。

定理1 指出，Outlier 样本对 Hessian 尾部特征值(即个别的高曲率方向)的贡献远大于 Inlier 样本。

$$\frac{\langle u_k, \nabla^2 l(z_o) u_k \rangle}{\langle u_k, \nabla^2 l(z_i) u_k \rangle} \geq C, \quad C > 1$$

其中 u_k 是高曲率方向的特征向量。

证明思路分析:

论文虽然将其放在附录，但思路很清晰。Outlier 样本因为与“共识”冲突，模型必须利用那些没有被通用知识占据的自由度(即在种群级看似平坦，但在实例级可以任意扭曲的方向)来“过拟合”这个点。这就像在一张平滑的桌布上，为了盖住一颗突出的钉子，桌布必须在那一点剧烈隆起(高曲率)。

3.4 跨视角验证: 输入空间与参数空间的同构

为了证明这个理论不是空中楼阁，作者还做了一个极其漂亮的“跨学科”验证 1。

他们不仅计算了权重的曲率，还计算了输入空间的曲率(即对抗攻击中常用的 Input Hessian Trace)。

结果显示:

- 对于隐私样本，输入曲率高，权重曲率也高(相关系数 0.78)。
- 这意味着信息的“高频”属性是守恒的。无论是在像素/Token层面(输入)，还是在神经元层面(权重)，隐私都表现为一种剧烈的波动。

这一点对于你的博士论文非常有启发性。也许我们可以建立一个统一的“信息几何场论”，将对抗样本(Adversarial Examples)和隐私泄露(Privacy Leakage)视为同一枚硬币的两面——它们都是高曲率流形的产物。

4. 数学严密性批判: 对角近似的“原罪”

到现在为止，我们都在赞美。现在，我们要拿出手术刀，切开这篇论文最脆弱的部位——近似。

4.1 影响函数与定理2的启发式推导

定理2 试图建立梯度投影与记忆化的关系:

$$\frac{\|P_{\mathcal{S}_{\text{mem}}}(g_i)\|^2}{\|g_i\|^2} \geq 1 - \epsilon$$

即记忆化样本的梯度几乎完全落在记忆子空间内。
作者使用了影响函数(Influence Functions)来推导这一点：

$$\Delta \theta \approx -H^{-1} \nabla l(z_i)$$

致命弱点：

作者自己也承认，在 2024-2025 年的研究中，多项证据表明在 LLM 这种高度非凸的模型中，逆 Hessian 向量积(iHVP)是不稳定的，甚至连符号都可能算错 1。

- LLM 的 Hessian 有大量的零特征值(Degenerate directions)。求逆本身就是病态的。
- 优化器(如 Adam)虽然模拟了二阶行为，但并没有真实的 Hessian 那么精确。

因此，作者将定理2 降级为“启发式推导(Heuristic Derivation)”。这在数学上是不严密的。这就像是用牛顿力学去推导量子效应——虽然结果可能碰巧对上了，但过程是错的。

4.2 对角 Hessian 近似 (Diagonal Hessian Approximation)

这是系统实现中的最大妥协。

理论上，Hessian 是一个 $d \times d$ 的巨大矩阵(对于 7B 模型， d 约为 70 亿)。计算它是不可能的。

LibOrtho 采用了对角近似：只看 H_{jj} ，忽略所有 H_{ij} ($i \neq j$)。

这意味着什么？

这意味着他们假设参数之间是独立的。

但我们知道，神经网络的魔力恰恰在于特征的组合(Feature Interaction)。如果一个隐私记忆(比如“张三住在海淀区”)不是由单个神经元存储，而是由层 A 的神经元 i 和层 B 的神经元 j 通过非线性激活共同编码的，那么这个记忆就存在于 Hessian 的非对角项中。

弥散性记忆 (Diffused Memory)：

这种存储在参数相关性中的记忆，被称为弥散性记忆。

LibOrtho 的对角筛选器 Impact_{ij} 无法检测到这种记忆。它会漏掉。

论文在 5.14 节的对比实验中诚实地展示了这一点：

- 对角近似：隐私泄露率 0.3%。
- **K-FAC** (块对角近似)：隐私泄露率 0.1%。
- 差异：有约 12% 的权重被 K-FAC 识别为重要，却被对角近似忽略¹。

这 12% 就是漏网之鱼。当 $\alpha=0$ 时，虽然大部分显性隐私(Spikes)被切除了，但这些隐性的、全息存储的隐私碎片(Diffused)依然残留在 Base 流中。

虽然 0.3% 的泄露率在工程上可能已经足够好(相比 98.5%)，但在理论上，这证明了几何隔离是不完美的。

4.3 纠缠度分布分析

作者在 5.10 节展示了纠缠度的分布直方图。

- 通用文本: 纠缠度 < 0.2 。
- 隐私数据: 纠缠度 > 0.5 。
- 数学题: 纠缠度介于两者之间, 且方差很大。

这不仅验证了理论, 也暴露了方法的局限性。对于那些纠缠度在 0.4-0.5 之间的样本(处于灰色地带), LibOrtho 很难处理。如果阈值设高了, 切不干净隐私; 设低了, 误伤通用能力。

这种分层解耦(Tiered Decoupling)策略, 本质上是在玩概率游戏, 尽管作者声称这是“确定性”的架构隔离。所谓的“确定性”, 指的是 α 乘法这个操作是确定性的, 但关于“哪些权重进 Ortho 流”的判断, 依然是基于统计特征的概率性判断。

5. 系统架构与工程美学: Linus Torvalds 的“好品味”

虽然我们批判了它的数学近似, 但不得不承认, 这篇论文的系统设计(System Design)具有极高的“品味”。

5.1 设计哲学

作者引用 Linus Torvalds 的原则: “好品味是将特殊情况视为正常情况。”¹

在传统的混合精度设计中, 稀疏分支通常需要复杂的 if-else 逻辑, 这会导致 Warp Divergence (线程束发散), 严重拖慢 GPU 速度。

LibOrtho 的设计非常聪明:

- 双流 **GEMM** 内核: 它不把 Ortho 流视为“异常处理”, 而是视为对同一块累加器(Accumulator)的“第二次写入”。
- **Warp** 专用融合:
 - 主 Warp 跑 INT4 Tensor Core(密集, 吞吐量大)。
 - 专用 Warp 跑 FP16 FMA(稀疏, 处理残差)。
 - 两者并行, 最后在 Shared Memory 中累加。

5.2 空测试 (Null Test) 的胜利

最让我印象深刻的是他们的“空测试”标准:

“当 $\alpha=0$ 或正交流为空时, 性能必须与纯 INT4 模型完全相同($<1\%$ 差异)。”¹

为了实现这一点, 他们在内核级别做了分支消除。

当 $\alpha=0$ 时, 代码路径完全跳过了稀疏计算的加载和执行。这使得 Base 模型($\alpha=0$)的延迟与标准的 bitsandbytes INT4 kernel 几乎一致(3.1ms vs 3.1ms)。

这在工程上是巨大的胜利。这意味着企业可以免费部署 LibOrtho。平时跑 Base 模式(省电、安全、快), 遇到专家模式需求时再开启 Ortho 流(稍慢, 13% 开销)。这种“零成本切换”的特性是它能走出实验室的关键。

5.3 侧信道攻击:阿喀琉斯之踵

然而,物理隔离带来了物理漏洞。作者在 6.0 节非常诚实地讨论了侧信道攻击(Side-Channel Attacks)¹。

这是一个非常严重的隐患,你需要特别注意。

由于 $\alpha=1$ 时需要执行额外的稀疏计算,这会消耗更多的时间和电量。

- 时序攻击(Timing Attack):攻击者可以通过测量 Token 生成的时间,推断模型是否激活了某些稀疏权重(尽管目前设计是静态稀疏,但如果未来引入动态激活,这将是致命的)。
- 功耗攻击(Power Attack):FP16 FMA 的能耗特征与 INT4 Tensor Core 完全不同。在云端共享 GPU 环境下,攻击者可以通过监控功率波动,推断出 Ortho 流的活动情况。

虽然作者提出了“恒定时间计算”(Dummy Computation)作为防御,但这又违背了“高效”的初衷。这是安全领域经典的“没有免费午餐”困境。

6. 实验验证:从 TOFU 到 MUSE 的全面碾压

论文采用了 2025 年最新的评估基准(TOFU, WMDP, MUSE),这显示了作者紧跟前沿的野心。

6.1 TOFU (虚构遗忘任务)

TOFU 是目前的金标准。结果令人震惊:

- LibOrtho ($\alpha=0$):遗忘集上的 Truth Ratio 为 0.52(随机是 0.5)。KS 统计量 0.08。这说明模型不仅是不记得了,而且在概率分布上表现得像从来没见过这些数据。
- Machine Unlearning (GU 等):Truth Ratio 0.68。说明还是有点印象,只是在强行压抑。

这验证了“架构隔离”优于“算法遗忘”。算法遗忘是在脑子里打补丁,架构隔离是直接切除了海马体的一部分。

6.2 关联知识提取:切断逻辑链条

这个实验¹非常有趣。

- 问:“张三住哪?”(直接提取) -> 拦截成功。
- 问:“海淀区有哪些姓张的名人?”(关联提取) -> 拦截成功(准确率从 85% 降至 12%)。

这说明 LibOrtho 切断的不仅仅是数据点本身,还有数据点在语义网络中的锚点。当高频的“特异性”被移除后,模型失去了从“海淀区”这个宽泛概念跳转到“张三”这个具体实体的能力。这种语义断连比单纯的数据擦除更彻底。

6.3 黄金区域 (Goldilocks Zone)

作者发现 $\alpha \in [0.2, 0.4]$ 是一个神奇的区域。

- $\alpha=0.2$ 时: 隐私泄露只有 32%(还可以接受), 但数学能力恢复到了 58%(比起 45% 强多了)。

这为实际应用提供了灵活性。也许我们不需要绝对的 0 或 1。我们可以给用户一个滑块。

- 儿童模式 ($\alpha=0$): 绝对安全, 禁止数学作业。
- 办公模式 ($\alpha=0.3$): 比较安全, 能处理 Excel 公式。
- 极客模式 ($\alpha=1$): 完整性能, 后果自负。

这种连续调节的能力, 是传统机器遗忘(要么忘, 要么记) 完全不具备的。

7. 结论与博士生指导建议

7.1 总结

LibOrtho 是一篇将几何直觉、数学近似与系统工程完美结合的范例。

- 理论上: 它统一了关于曲率的矛盾, 提出了“隐私即高频噪声”的流形观。
- 工程上: 它实现了零开销的隐私开关, 且不破坏现有的推理栈。
- 哲学上: 它挑战了“智能必须完整”的观念, 提出了“分辨率缩放智能”。

7.2 对你研究的建议

作为你的导师, 我建议你从以下几个“漏洞”入手, 展开你的博士研究:

1. 攻破对角近似: 既然 LibOrtho 忽略了非对角项, 你能不能设计一种对抗攻击(**Adversarial Attack**), 专门针对“弥散性记忆”? 试着构造一种 Prompt, 它能激活那些虽然单个权重曲率低、但组合起来曲率极高的路径。如果能做到这一点, 你就击穿了 LibOrtho 的防线。
2. 动态流形追踪: LibOrtho 目前的 \mathcal{S}_{mem} 是静态定义的(离线计算)。但人类的记忆是动态的。你能不能引入在线学习, 让 Ortho 流随着新的对话实时更新? 这需要你在推理时进行低秩 Hessian 更新(Low-Rank Hessian Update)。
3. 形式化验证: 定理2 是启发式的。你能不能在更简单的模型(如单层 Transformer)上, 给出严格的数学证明? 证明在什么条件下, 梯度会完全正交于通用子空间。

这篇论文是 2025 年 LLM 安全领域的一个里程碑。它不仅仅是一个工具, 更是一个思想实验。它告诉我们, 也许我们不需要让 AI 学会“遗忘”, 我们只需要让它把记忆放在另一个“抽屉”里, 然后把钥匙扔掉。

去吧, 把那个 K-FAC 的对比实验复现一下。如果那个 12% 的差距是真的, 那这就是你下一篇顶级会议论文的起点。

Prof.

附录: 核心数据速查表

为了方便你对比, 我从论文中整理了关键数据:

指标	LibOrtho ($\alpha=0$) (安全模式)	LibOrtho ($\alpha=1$) (完整模式)	Machine Unlearning (SOTA)	纯 INT4 基线
Canary 提取率 (隐私)	0.3% (接近随机)	98.5%	~45%	N/A
MMLU 分数 (通用智能)	66.5%	68.1%	~60% (显著下降)	66.2%
GSM8K 准确率 (数学/脆性)	45% (显著下降)	68%	52%	<10% (INT3)
WMDP 准确率 (危险知识)	12% (消除成功)	85%	45%	N/A
TOFU 遗忘质量 (Truth Ratio)	0.52 (完美遗忘)	1.0	0.68	N/A
推理延迟 (A100)	3.1 ms (1.0x)	3.5 ms (1.13x)	N/A (需重新训练)	3.1 ms
主要缺陷	丢失数学能力, 存在侧信道	存在隐私泄露	计算昂贵, 遗忘不彻底	无法控制隐私

数据来源: ¹ Table 1, Table 2, Figure 3 及相关章节文本。

Works cited

1. libortho_paper_zh.pdf